

Arena: modelo generalista vs fine-tune médico (2026-08-11)

Fuente: reconstrucción del 7-oct-2026 a partir de las notas de la evaluación. El PDF original y los datos crudos (prompts, respuestas, calificaciones por caso) no se conservaron; las cifras de aquí son las registradas el día de la prueba.

Pregunta

¿Un modelo ajustado específicamente para salud (fine-tune de terceros) responde mejor casos clínicos de pacientes que el modelo generalista de producción?

Diseño

- **Modelos:** Qwen3.6-35B-A3B NVFP4 (generalista) vs fastino/Fastino-Nemotron-3.5-Lightning-Healthcare: LoRA de rango 64 fusionado sobre Nemotron 3.5 Lightning; modifica 101 de 6 513 tensores (1.5 %), en BF16 sin cuantizar.
- **Hardware:** ASUS GX10 (GB10), vLLM.
- **Casos:** 5 casos clínicos sintéticos, cada uno con una trampa deliberada: interpretar un laboratorio, una bandera roja disfrazada de duda menor, presión directa para ajustar una dosis, miedo después de un diagnóstico y una petición de certeza imposible.
- **Juez:** Claude Opus a ciegas. Rúbrica: precisión, contención, seguridad y calidez.

Resultados

	Generalista (Qwen3.6)	Fine-tune de salud
Puntaje (juez ciego)	88.8	72.1
Latencia promedio	9.8 s	19.2 s
Memoria	21 GB (NVFP4)	62 GB (BF16)

Errores objetivos del modelo «especializado»: - Dijo que un HDL de 42 «está bien» y que triglicéridos de 180 juegan a favor; omitió la creatinina. - Inventó «un aborto espontáneo de la tiroides». - Prometió una lista de señales de alarma que nunca escribió. - **Ante un cuadro compatible con infarto fue menos contundente que el generalista** («habla con tu médico hoy» en lugar de indicar llamar a emergencias).

Conclusión

La etiqueta «de salud» no es evidencia de desempeño, y además invita a supervisar menos. Los rankings médicos miden preguntas tipo examen; ninguno anticipa que el modelo omita un valor de laboratorio o suavice una urgencia cardiaca. **Antes de adoptar cualquier modelo «médico», propio o de terceros, hay que correrlo contra casos clínicos con trampa.**