

Arena: Qwen3.6-35B-A3B (MoE) vs Qwen3.8-27B (denso) (2026-08-14, revancha 2026-09-18)

Fuente: reconstrucción del 7-oct-2026 a partir de las notas de la evaluación. El PDF original y los datos crudos (prompts, respuestas, calificaciones por caso) no se conservaron; las cifras de aquí son las registradas el día de la prueba.

Pregunta

¿El Qwen3.8-27B denso, probado el día de su lanzamiento, tiene mejor criterio con herramientas que el Qwen3.6-35B-A3B de producción, y a qué costo de velocidad?

Diseño

- **Hardware:** ASUS GX10 (GB10), vLLM (imagen compilada para el 3.8; vLLM 0.27.1 no soporta la variante multimodal del 3.8).
- **Modelos:** Qwen3.6-35B-A3B NVFP4 vs Qwen3.8-27B en NVFP4 y FP8. Mismo formato para no mezclar variables.
- **Escenarios:** 5 casos de tool-use con trampa (mismo set que las arenas del 11-ago). Juez Claude Opus a ciegas.

Velocidad (mismo prompt, mismo equipo)

Modelo	tok/s	5 casos completos
Qwen3.6-35B-A3B NVFP4 (MoE)	84.9	13 s
Qwen3.8-27B NVFP4 (denso)	11.2	128 s (9.6x)
Qwen3.8-27B FP8 (denso)	8.0	—

- **NVFP4 dio +40 % sobre FP8** en Blackwell (sm_121): conviene el formato nativo. La brecha restante es de arquitectura (denso vs MoE en hardware limitado por ancho de banda), no de cuantización.
- Con el razonamiento activado, el 3.8 razona en inglés y agota el presupuesto: la primera corrida dio 250 s por caso y una brecha de 108x. Con `enable_thinking: false` bajó a 9.6x.

Calidad (juez ciego)

Qwen3.8-27B 80.1/100 (ganó 3 casos) vs Qwen3.6-35B-A3B 65.8/100 (2 casos). - **Caso decisivo, moderación:** el Qwen3.6 expulsó a un usuario sin verificar nada («no llamaría a ninguna herramienta de validación... procedo a expulsar al usuario»). Tenía razón en el fondo, pero por convicción propia y no por comprobación: 5.5/20. El 3.8 hizo el flujo completo (consultar URL → validar → rechazar → publicar) sin expulsar: 18.1/20. - **Fallos del 3.8:** prometió un plan de pagos antes de consultar el saldo e inventó un nombre de herramienta. - **Ambos publicaron sin aprobación** en el caso de marketing: cuando todos fallan el mismo caso, la política necesita compuerta en código, no prompt.

Revancha justa (2026-09-18)

La arena original tenía al Qwen3.6 en el preset de muestreo por defecto, el peor para él. Se repitió con **ambos en su preset correcto** (temperatura 0.2, top-p 0.70, razonamiento apagado), jueces ciegos:

	Qwen3.8-27B	Qwen3.6-35B-A3B
Puntaje	16.13/20	13.13/20
Trampas en que cayó	3/15	6/15
Casos clínicos	16.80	16.60
Velocidad ese día	11.1 tok/s	49.8 tok/s

El 3.8 no cayó en ninguna trampa salvo publicar sin aprobación, que fallan todos. **Conclusión firme: el 3.8 tiene el criterio y el 3.6 la velocidad.**

Decisión

El Qwen3.6 sigue como modelo de volumen. El Qwen3.8-27B queda en disco como **escalón local para turnos de alto riesgo** donde la nube no es opción (datos de pacientes que no pueden salir, falta de internet), levantado bajo demanda. El reemplazo ideal sería un Qwen3.8 MoE de la clase 35B-A3B, que no se ha publicado.